

## Fazendo contas com matrizes e vetores

Esse é um capítulo sobre contas e algumas definições básicas que serão essenciais durante o curso. Embora pareça maçante (e muitas vezes seja mesmo), precisamos nos certificar de que entendemos as definições e operações básicas antes de prosseguirmos. Não subestime esse capítulo: saber fazer uma conta de várias maneiras diferentes ou mesmo escrever de várias maneiras diferentes muitas vezes é o segredo para conseguir demonstrar um teorema ou desenhar um algoritmo mais eficiente.

Neste capítulo, consideraremos  $\vec{v}$  e  $\vec{w}$  vetores com entradas

$$\vec{v} = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} \in \mathbb{R}^n \text{ e } \vec{w} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix} \in \mathbb{R}^n,$$

além de  $A$  e  $B$  matrizes com  $m \times n$  e  $n \times p$  entradas<sup>4</sup>, ou seja,

<sup>4</sup> Ou seja,  $m$  linhas e  $n$  colunas

$$A = (a_{ij})_{m \times n} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

e

$$B = (b_{ij})_{n \times p} = \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1p} \\ b_{21} & b_{22} & \cdots & b_{2p} \\ \vdots & \ddots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{np} \end{bmatrix}.$$

### Somando e multiplicando

Podemos somar vetores e também multiplicar por escalares realizando as operações coordenada a coordenada. Se  $\alpha \in \mathbb{R}$ , então

$$\alpha \vec{v} + \vec{w} = \begin{bmatrix} \alpha v_1 + w_1 \\ \alpha v_2 + w_2 \\ \vdots \\ \alpha v_n + w_n \end{bmatrix}.$$

Também podemos multiplicar uma matriz por um escalar  $\alpha \in \mathbb{R}$  realizando a multiplicação coordenada a coordenada, ou seja

$$\alpha A = (\alpha a_{ij})_{m \times n} = \begin{bmatrix} \alpha a_{11} & \alpha a_{12} & \cdots & \alpha a_{1n} \\ \alpha a_{21} & \alpha a_{22} & \cdots & \alpha a_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ \alpha a_{m1} & \alpha a_{m2} & \cdots & \alpha a_{mn} \end{bmatrix}.$$

Como  $A$  tem  $n$  colunas e  $\vec{v}$  tem  $n$  coordenadas podemos multiplicar  $A\vec{v}$  e obter um vetor de  $m$  coordenadas da forma

$$A\vec{v} = \begin{bmatrix} a_{11}v_1 + a_{12}v_2 + \cdots + a_{1n}v_n \\ a_{21}v_1 + a_{22}v_2 + \cdots + a_{2n}v_n \\ \vdots \\ a_{m1}v_1 + a_{m2}v_2 + \cdots + a_{mn}v_n \end{bmatrix} \in \mathbb{R}^m.$$

A multiplicação de duas matrizes  $A$  e  $B$ , denotada por  $AB$ , é uma operação definida quando o número de colunas de  $A$  é igual ao número de linhas de  $B$ . Se  $A$  é uma matriz  $m \times n$  e  $B$  é uma matriz  $n \times p$ , então o produto  $AB$  resultará em uma matriz  $m \times p$ . A entrada  $(i, j)$  da matriz resultante  $AB$  é obtida multiplicando cada elemento da  $i$ -ésima linha de  $A$  pelos elementos correspondentes da  $j$ -ésima coluna de  $B$  e somando esses produtos. Matematicamente, a entrada  $(i, j)$  de  $C = AB$  é dada por <sup>5</sup>:

$$c_{ij} = a_{i1}b_{1j} + a_{i2}b_{2j} + \cdots + a_{in}b_{nj} = \sum_{k=1}^n a_{ik}b_{kj}.$$

É interessante notar que o produto de  $A\vec{v}$  pode ser visto como um produto de matrizes. Basta interpretar  $\vec{v}$  como uma matriz de  $n$  linhas e 1 coluna.

Por fim, note que **o produto de matrizes não é comutativo!**<sup>6</sup> Ou seja, pode ocorrer que  $AB \neq BA$  mesmo quando  $n = m = p$  e o produto está bem definido. Por outro lado, **o produto de matriz é associativo**, ou seja, se  $A, B$  e  $C$  são matrizes e a multiplicação  $ABC$  faz sentido, então  $ABC = (AB)C = A(BC)$ .

<sup>5</sup> Talvez seja preciso gastar um tempinho entendendo o somatório abaixo (somatório é o nome desse  $\Sigma$  grande com índice  $k$  indo de  $k = 1$  até  $k = n$ ).

<sup>6</sup> Tome, por exemplo,  $A = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}$  e  $B = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$

### A transposta e a inversa de uma matriz

A transposta de uma matriz  $A$ , denotada por  $A^T$ , é obtida trocando suas linhas por colunas e vice-versa. Se  $A$  é uma matriz  $m \times n$ , então a matriz transposta  $A^T$  terá dimensões  $n \times m$ . Logo:

$$A^T = (a_{ji})_{n \times m} = \begin{bmatrix} a_{11} & a_{21} & \cdots & a_{m1} \\ a_{12} & a_{22} & \cdots & a_{m2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1n} & a_{2n} & \cdots & a_{mn} \end{bmatrix}.$$

Note que enquanto o produto por  $A$  mapeia vetores de  $\mathbb{R}^n$  para  $\mathbb{R}^m$ , o produto por  $A^T$  faz o contrário: mapeia vetores de  $\mathbb{R}^m$  para  $\mathbb{R}^n$ .

Como o produto entre uma matriz  $A$  e um vetor  $\vec{v} \in \mathbb{R}^n$  mapeia  $\vec{v}$  em um vetor  $A\vec{v} \in \mathbb{R}^m$ , é natural pensar na matriz que realiza a operação inversa. Dizemos que uma matriz  $C$  ( $n \times m$ ):

- é inversa pela direita de  $A$  se  $AC = I_m$ ;
- é inversa pela esquerda de  $A$  se  $CA = I_n$ ;
- é inversa de  $A$  se é inversa pela esquerda e pela direita.

Acima usamos que  $I_n$  é a matriz identidade

$$I_n = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix}_{n \times n}.$$

Nem todas as matrizes tem inversa, nem inversa pela direita ou pela esquerda. Quando  $A$  tem inversa denotamos a inversa de  $A$  por

$$A^{-1}.$$

De fato, saber se uma matriz tem ou não inversa é um problema muito próximo do problema de resolver sistemas lineares<sup>7</sup>. Portanto, é o propósito de boa parte do nosso curso.

<sup>7</sup> Por que?

### Algumas propriedades

Seja  $B$  inversa pela esquerda de  $A$  e  $C$  inversa pela direita de  $A$ , então

$$B = BI_m = B(AC) = (BA)C = I_n C = C.$$

Logo, se  $A$  tem inversa pela direita e pela esquerda as inversas são iguais. Ou seja, a inversa  $A^{-1}$  de uma matriz invertível é única.

Além disso, como veremos no futuro, apenas matrizes quadradas (com  $n = m$ ) podem possuir inversa. Por enquanto, vamos fingir que não sabemos disso.

As operações que discutimos satisfazem as seguintes propriedades:

- $(AB)^T = B^T A^T$ ;
- Quando  $A$  e  $B$  possuem inversa, então  $AB$  é invertível e  $(AB)^{-1} = B^{-1} A^{-1}$ ;
- Quando a inversa de  $A$  existe, então a inversa da inversa de  $A$  é  $A$ , em outras palavras,  $(A^{-1})^{-1} = A$ ;
- Se  $\alpha \neq 0$  e  $A$  tem inversa, então  $(\alpha A)^{-1} = \frac{1}{\alpha} A^{-1}$ ;
- Se  $A$  é invertível, inversa e transposta comutam, ou seja,  $(A^T)^{-1} = (A^{-1})^T$ ;

Vá em frente, tente provar essas propriedades. Aqui vamos provar apenas a última propriedade. Basta mostrar que

$$A^T(A^{-1})^T = I_n \text{ e } (A^{-1})^T A^T = I_m.$$

Podemos usar a primeira propriedade da lista, mostrando que

$$A^T(A^{-1})^T = (A^{-1}A)^T = I_n^T = I_n$$

e

$$(A^{-1})^T A^T = (AA^{-1})^T = I_m^T = I_m.$$

### *A norma Euclideana e o produto escalar*

Uma propriedade muito importante na definição física de vetor é o seu módulo ou tamanho, que aqui conheceremos como norma Euclideana. A norma Euclideana de um vetor  $\vec{v}$  é denotada por  $\|\vec{v}\|_2$  e é definida como<sup>8</sup>

$$\|\vec{v}\|_2 = \sqrt{v_1^2 + v_2^2 + \cdots + v_n^2}.$$

Definimos também o produto interno entre dois vetores  $\vec{v}, \vec{w} \in \mathbb{R}^n$  como

$$\langle \vec{v}, \vec{w} \rangle = v_1 w_1 + v_2 w_2 + \cdots + v_n w_n = \sum_{i=1}^n v_i w_i.$$

O produto interno tem uma interpretação natural em termos da lei dos cossenos. Quaisquer dois vetores  $\vec{v} \in \mathbb{R}^n$  e  $\vec{w} \in \mathbb{R}^n$  quando posicionados numa mesma origem definem um plano (e isso independe de  $n$ !). Nesse plano esses vetores definem um ângulo  $\theta$ .

<sup>8</sup> Note que a definição se parece muito com o Teorema de Pitágoras. Isso não é uma coincidência.

Podemos formar um triângulo com lados de tamanhos  $\|\vec{v}\|_2$ ,  $\|\vec{w}\|_2$  e  $\|\vec{w} - \vec{v}\|_2$ . Além disso, o ângulo  $\theta$  entre  $\vec{v}$  e  $\vec{w}$  aparece no triângulo.

A lei dos cossenos diz que um triângulo de vértices  $PQR$  satisfaz

$$|QR|^2 = |PQ|^2 + |PR|^2 - 2|PQ||PR|\cos(\widehat{RPQ}).$$

Aplicando a lei dos cossenos no triângulo da Figura 8 temos

$$\|\vec{w} - \vec{v}\|_2^2 = \|\vec{v}\|_2^2 + \|\vec{w}\|_2^2 - 2\|\vec{v}\|_2\|\vec{w}\|_2\cos\theta,$$

além disso, vale que (faça as contas)

$$\|\vec{w} - \vec{v}\|_2^2 = \|\vec{v}\|_2^2 + \|\vec{w}\|_2^2 - 2\langle \vec{v}, \vec{w} \rangle.$$

Logo,

$$\langle \vec{v}, \vec{w} \rangle = \|\vec{v}\|_2\|\vec{w}\|_2\cos\theta. \quad (2)$$

A identidade (2) fornece uma interpretação geométrica muito útil para aplicações. Assuma que  $\|\vec{v}\|_2$  e  $\|\vec{w}\|_2$  são fixas, mas que podemos escolher  $\vec{v}$  e  $\vec{w}$  de maneira a variar o ângulo  $\theta$ : quando o produto escalar é alto então  $\vec{v}$  e  $\vec{w}$  estão próximos; quando o produto escalar é próximo de zero então  $\vec{v}$  e  $\vec{w}$  são quase perpendiculares; quando o produto escalar é negativo e com valor absoluto alto então  $\vec{v}$  e  $\vec{w}$  apontam em sentidos opostos. Ou seja, **o produto escalar mede a similaridade entre dois vetores**.<sup>9</sup>

O produto escalar e a norma Euclideana estão relacionados por

$$\|\vec{v}\|_2 = \sqrt{\langle \vec{v}, \vec{v} \rangle}$$

e

$$\langle \vec{v}, \vec{w} \rangle = \frac{\|\vec{v} + \vec{w}\|_2^2 - \|\vec{v}\|_2^2 - \|\vec{w}\|_2^2}{2}.$$

Além disso, valem as seguintes propriedades (prove):

- O produto escalar é simétrico, ou seja,  $\langle \vec{v}, \vec{w} \rangle = \langle \vec{w}, \vec{v} \rangle$ ;
- Além disso, para  $\vec{v}, \vec{w}, \vec{u} \in \mathbb{R}^n$  e  $\alpha \in \mathbb{R}$ ,

$$\langle \alpha \vec{v} + \vec{w}, \vec{u} \rangle = \alpha \langle \vec{v}, \vec{u} \rangle + \langle \vec{w}, \vec{u} \rangle.$$

Vale observar também que as propriedades vistas aqui valem em maior generalidade com as definições certas. Veremos no futuro que a norma Euclideana é apenas um exemplo de norma e que o produto escalar entre vetores é apenas um exemplo de produto interno. Além disso, as propriedades vistas vão continuar valendo em maior generalidade.




Figura 8: Dados vetores  $\vec{v}$  e  $\vec{w}$  podemos formar um triângulo relacionando as normas Euclidianas e o ângulo  $\theta$  entre os vetores.

<sup>9</sup> Uma curiosidade: a regressão linear, um dos métodos clássicos de aprendizado de máquina, usa o produto escalar como medida de similaridade.

### O traço de uma matriz

Definimos também mais uma operação relevante, o traço, que será definido apenas para matrizes quadradas. Definimos

$$\text{tr}(A) = \sum_{i=1}^n a_{ii}.$$

Além disso, o traço satisfaz as seguintes propriedades:

- O traço é linear. Seja  $\alpha$  um escalar e  $A$  e  $B$  matrizes  $n \times n$ , então:

$$\text{tr}(\alpha A + B) = \alpha \text{tr}(A) + \text{tr}(B).$$

- O traço do produto não depende da ordem:

$$\text{tr}(AB) = \text{tr}(BA).$$

### Exercícios

**Exercício 1.** Mostre que se existe um vetor  $\vec{v} \neq \vec{0}$  tal que  $A\vec{v} = \vec{0}$  então  $A$  não possui inversa. Nesse caso, é possível que  $A$  tenha inversa pela direita? E pela esquerda?

**Exercício 2.** Sejam  $\vec{v}, \vec{w} \in \mathbb{R}^n$  vetores e  $V, W$  as matrizes  $n \times 1$  correspondentes aos vetores. Mostre que

$$(i) \quad \langle \vec{v}, \vec{w} \rangle = V^T W = \text{tr}(VW^T).$$

(ii) Se  $A = (a_{ij})_{n \times n}$ , então

$$\langle \vec{v}, A\vec{w} \rangle = V^T A W = \sum_{i,j \in [n]} a_{ij} v_i w_j = W^T A^T V = \langle A^T \vec{v}, \vec{w} \rangle.$$

**Exercício 3.** Uma das mais conhecidas arquiteturas para redes neurais é o multilayer perceptron, cuja arquitetura baseia-se em compor multiplicações por matrizes com ativações não-lineares. Tome  $A$  uma matriz  $m \times n$  e  $B$  uma matriz  $p \times m$ . Defina  $\sigma : \mathbb{R}^m \mapsto \mathbb{R}^m$  como sendo a aplicação  $x \mapsto \max(0, x)$  coordenada a coordenada, ou seja,  $\sigma$  zera as entradas negativas e preserva as entradas positivas. Chamamos  $\sigma$  de função de ativação<sup>10</sup>. Uma rede  $\varphi : \mathbb{R}^n \mapsto \mathbb{R}^p$  com duas camadas lineares é dada pelo mapa

$$\varphi(\vec{v}) = B\sigma(A\vec{v}),$$

onde as matrizes  $A$  e  $B$  normalmente são aprendidas treinando a rede neural. Escolha  $m, p, A$  e  $B$  de maneira que  $\varphi$  seja a função identidade em  $\mathbb{R}^n$ . Justifique sua escolha.

<sup>10</sup> Essa escolha de  $\sigma$  em específico é conhecida como ReLU.